

**Lineares Ausgleichsproblem:**

Daten: 

$t_i$	0	1	2	3
$y_i$	3	2,14	1,8	1,72

 Modellfunktion:  
 $y(t) = \alpha^{1/1+t} + \beta$

$$A = \begin{pmatrix} y(t_1=0) \\ y(1) \\ y(2) \\ y(t_n=3) \end{pmatrix} \cdot \begin{pmatrix} \alpha \\ \beta \end{pmatrix}; b = \begin{pmatrix} y_1=3 \\ 2,14 \\ 1,86 \\ y_n=1,72 \end{pmatrix}$$
$$\rightsquigarrow \begin{pmatrix} 1 & 1 \\ 1/2 & 1 \\ 1/3 & 1 \\ 1/4 & 1 \end{pmatrix} \cdot \begin{pmatrix} \alpha \\ \beta \end{pmatrix} = \begin{pmatrix} y_1=3 \\ 2,14 \\ 1,86 \\ y_n=1,72 \end{pmatrix}$$

**Satz: 1.1:**

$x^* \in \mathbb{R}$  ist genau dann eine Lösung des linearen Ausgleichsproblems, wenn  $x^*$  Lösung der Normalgleichung  $A^T A x = A^T b$  ist. Es gibt mindestens eine Lösung  $x^*$ . Sie ist eindeutig, gdw.  $\text{Rang}(A) = n$ .

**Satz: 1.2:**

Sei  $A \in \mathbb{R}^{m \times n}$ ,  $b \in \mathbb{R}^m$  mit QR-Zerlegung von  $A$ ,  $\text{Rang}(A) \equiv n$ ,  $A = QR$ ,  $R = \begin{pmatrix} R_1 \\ 0 \end{pmatrix}$ ,  $R_1 \in \mathbb{R}^{n \times n}$  und  $\begin{pmatrix} c_1 \\ c_2 \end{pmatrix} := Q^T b$  mit  $c_1 \in \mathbb{R}^n$ ,  $c_2 \in \mathbb{R}^{m-n}$ . Dann gilt:  
 $R_1$  ist regulär und  
Außerdem gilt:  $\|b - Ax\|_2 = \|c_2\|$ .

**Hessenbergmatrix durch Householder-Reflexion:**

Mithilfe einer Householder-Reflexion, dargestellt durch Matrixmultiplikation  $Q_u \cdot A$ , kann ein Teil der Matrix zu null transformiert werden. Mit  $v$  als Spaltenvektor von  $A$ , welcher die erste Spalte enthält, wird  $u := v + \text{sgn}(v_1) \cdot e_1 \cdot \|v\|$  gewählt ( $\text{sgn}(\cdot)$  ist die Vorzeichenfunktion, jedoch muss bei 0 nicht 0 genommen werden!). Damit wird  $Q_u := \mathbb{1}_{m \times m} - 2 \cdot (u \cdot u^T) / (u^T \cdot u)$  definiert, welche  $A$  so verdrehspiegelt, dass alle Elemente in der ersten Spalte unterhalb der Diagonalen verschwinden. Nun kann man weiter vorgehen und die Teilmatrix von  $A$  hernehmen, welche die erste Zeile und Spalte gestrichen hat und darauf weiter agieren. Am ende hätte man mindestens eine obere rechte Dreiecksmatrix. Das Produkt aller verwendeten  $Q$  wäre dann eine orthogonale Matrix, womit  $Q \cdot R = A$  als QR-Zerlegung entstanden ist.

**Eigenschaften der Householder-Reflexion:**

- (i)  $Q_v \cdot v = -v$
- (ii)  $Q_v \cdot u = u \Leftrightarrow v \perp u$
- (iii)  $Q_v^T = Q_v^{-1} \Rightarrow Q_v$  ist Orthogonal

Eine **Givensrotation** von  $A = \begin{pmatrix} a_1 & * \\ a_2 & * \end{pmatrix}$  kann mit  $r = \left| \sqrt{a_1^2 + a_2^2} \right|$ ,  $c = a_1/r$ ,  $s = a_2/r$  und  $G = \begin{pmatrix} c & s \\ -s & c \end{pmatrix}$  erfolgen:  $G \cdot A = \begin{pmatrix} r & * \\ 0 & * \end{pmatrix}$

**Nichtlineares Ausgleichsproblem:**

Daten: 

$t_i$	0	1	2
$y_i$	2	-3	4

 Modellfunktion:  
 $y(t) = x_1 \sin(x_2 \cdot t)$

$$\varphi(t, x) = y(t)$$
$$F_i = y_i - \varphi(t_i, x)$$

$$\mathbb{R}^n \ni F(x) = \begin{pmatrix} 2 - 0 \\ -3 - x_1 \sin(x_2) \\ 4 - x_1 \sin(2x_2) \end{pmatrix}$$
$$J_F(x) = \begin{pmatrix} 0 & 0 \\ -\sin(x_2) & -x_1 \cos(x_2) \\ -\sin(2x_2) & -2x_1 \cos(2x_2) \end{pmatrix}$$

$$\|F(x)\|_2^2 \approx \|F(x^{(k)}) + J_F(x^{(k)})(x - x^{(k)})\|_2^2 \} \rightarrow \min$$

**Algorithmus: Gauß-Newton-Verfahren**

- 1: Wähle Startvektor  $x^{(0)} \in \mathbb{R}$
- 2: **for**  $k = 0, 1, \dots$  **do**
  - ▷ Löse LGS nach  $\Delta x^{(k)}$
- 3:  $\|J_F(x^{(k)})\Delta x^{(k)} + F(x^{(k)})\|_2^2 \rightarrow \min$
- 4: setze  $x^{(k+1)} = x^{(k)} + \Delta x^{(k)}$
- 5: **end for**

$A \in \mathbb{R}^{n \times n}$  s.p.d  $\Rightarrow \exists V \in \mathbb{R}^{n \times n}$  orthogonal mit  $V^T A V = D$ ;  $d_{ii} = \lambda_i \geq 0 \Rightarrow A = V D V^T$  ( $V V^T = \mathbb{1}$ )  
 $AV = VD$

$A \in \mathbb{R}^{m \times n}$   $A^T A$  ist s.p.semi-d.  $x^T A^T A x \geq 0$   
**Satz: Singulärwertzerlegung:**  
Sei  $A \in \mathbb{R}^{m \times n}$  und  $p = \min(m, n)$ . Dann existieren orthogonale Matrizen  $U \in \mathbb{R}^{m \times m}$  und  $V \in \mathbb{R}^{n \times n}$  mit  $U^T A V = \Sigma = \text{diag}(\sigma_1, \dots, \sigma_p) \Rightarrow$   $A = U \Sigma V^T$

**Anwendung der SVD**

- (i)  $A^{(s)} := \sum_{i=1}^n \sigma_i u_i v_i^T$ ,  $s < r$  ist die beste (im Sinne der  $\|\cdot\|_2$ ) Approximation von  $A$  mit dem Rang(s).
- (ii) **Pseudoinverse**  $A^+$ ,  $A \in \mathbb{R}^{m \times n}$ ;  
 $A = U \Sigma V^T$ ;  
 $A^+ = V \Sigma^+ U^T$  mit  $\Sigma^+ = \begin{pmatrix} 1/\sigma_1 & 0 & 0 \\ 0 & 1/\sigma_r & 0 \\ 0 & 0 & 0 \end{pmatrix}$ ;  
 $x = A^+ b$  ist die Lösung des linearen Ausgleichsproblems  $\|Ax - b\|_2 \rightarrow \min$
- (iii) Lösung des linearen Ausgleichsproblems für  $\text{Rang}(A) < n$
- (iv) Regularisierung schlecht gestellter Probleme  
 $\hat{x} = \sum_{i=1}^s 1/\sigma_i v_i \cdot (u_i^T \cdot b)$ ,  $s < n$

**Algorithmus: Vektoriteration**

- 1: wähle  $x^{(0)} \in \mathbb{R}$ , setze  $y^{(0)} = x^{(0)} / \|x^{(0)}\|_2$
- 2: **for**  $k = 0, 1, \dots$  **do**
- 3:  $x^{k+1} = A \cdot y^{(k)}$
- 4:  $\lambda^{(k)} = y^{(k)T} \cdot x^{(k)}$
- 5:  $y^{k+1} = x^{(k+1)} / \|x^{(k+1)}\|_2$
- 6: **end for**

**Algorithmus: Inverse Vektoriteration mit Spektralverschiebung**

- 1: wähle  $x^{(0)} \in \mathbb{R}$ , setze  $y^{(0)} = x^{(0)} / \|x^{(0)}\|_2$
- 2: **for**  $k = 0, 1, \dots$  **do**
- 3: Löse LGS  $(A - \mu \mathbb{1}) x^{(k+1)} = y^{(k)}$ 
  - ▷  $\Leftrightarrow x^{(k+1)} = (A - \mu \mathbb{1})^{-1} \cdot y^{(k)}$
- 4:  $\lambda^{(k+1)} = 1/y^{(k)T} \cdot x^{(k)} + \mu$
- 5:  $y^{k+1} = x^{(k+1)} / \|x^{(k+1)}\|_2$
- 6: **end for**

**Lemma zum QR-Verfahren**

- (i) die Matrizen  $A_k$  sind **ähnlich** zu  $A$ .
  - (ii)  $A$  Symetrisch  $\Rightarrow A_k$  Symmetrisch.
  - (iii)  $A$  tridiagonal und Symetrisch  $\Rightarrow A_k$  auch.
- Zwei Matrizen  $A$  und  $B$  sind sich **ähnlich**, wenn es eine reguläre Matrix  $S$  gibt, so dass:  $B = S^{-1} \cdot A \cdot S \Leftrightarrow SB = AS$  gilt.  
Ähnliche Matrizen haben dasselbe Spektrum  $\sigma(A) = \sigma(B)$ , gleiche Spur, gleichen Rang aber nicht notwendigerweise die gleichen EV.

**Algorithmus: QR-Verfahren mit Spektralverschiebung**

- 1:  $A_0 = P^T \cdot A \cdot P$ 
  - ▷ Tridiagonaltransformation
- 2: **for**  $k = 0, 1, \dots$  **do**
- 3: wähle  $\mu_k \in \mathbb{R}$
- 4:  $A_k - \mu_k \mathbb{1} = Q_k \cdot R_k$ 
  - ▷ QR-Zerlegung
- 5:  $A_{k+1} = R_k \cdot Q_k + \mu_k \mathbb{1}$ 
  - ▷  $= Q_k^T A_k Q_k$
- 6: **end for**

**Lagrange-Fundamental-Polynom**

Seien Stützpunkte  $(x_i, f_i)$   $i = 0, \dots, n$  gegeben: Suche Polynome  $\ell_j \in \Pi_n$ ,  $j = 0, \dots, n$  mit

$$\ell_j(x_k) = \begin{cases} 1 : j = k \\ 0 : j \neq k \end{cases};$$
$$P(f|x_0, \dots, x_n)(x) \stackrel{?!}{=} \sum_{j=0}^n f_j \cdot \ell_j(x);$$

$$\ell_j = \prod_{\substack{i=0 \\ i \neq j}}^n \frac{x - x_i}{x_j - x_i}$$

**Newton-Basis:**

$$P(f|x_0, \dots, x_n)(x) = \sum_{i=0}^n b_i \omega_i(x) = \sum_{i=0}^n b_i \prod_{p=0}^i (x - x_p)$$
$$b_k = f_{[x_0, \dots, x_k]}$$
$$f_{[x_r, \dots, x_s]} = (f_{[x_{r+1}, \dots, x_s]} - f_{[x_r, \dots, x_{s-1}]}) / (x_r - x_s)$$
$$\omega_j(x) = \prod_{i=0}^j (x - x_i), \omega_0(x) = 1$$

**Algorithmus: Horner-Schema**

- 1:  $p = b_n$
- 2: **for**  $k = n - 1, \dots, 1, 0$  **do**
- 3:  $p = b_n + (x - x_k) \cdot p$
- 4: **end for**

**Abschätzung;**

**Satz:** Seien  $x_0, \dots, x_n$  Paarweise unterschiedliche Stützstellen,  $x_i \in [a, b]$  und  $f \in C^{n+1}([a, b])$ . Dann gilt für  $x \in [a, b]$

$$|f(x) - P(f|x_0, \dots, x_n)(x)| \leq |\omega_{n+1}| \max_{z \in [a, b]} \frac{|f^{(n+1)}(z)|}{(n+1)!}$$

	0°	30°	45°	60°	90°
sin(α)	0	$\frac{1}{2}$	$\frac{1}{2}\sqrt{2}$	$\frac{1}{2}\sqrt{3}$	1
cos(α)	1	$\frac{1}{2}\sqrt{3}$	$\frac{1}{2}\sqrt{2}$	$\frac{1}{2}$	0
tan(α)	0	$\frac{1}{3}\sqrt{3}$	1	$\sqrt{3}$	–
cot(α)	–	$\sqrt{3}$	1	$\frac{1}{3}\sqrt{3}$	0